Semistrukturierte Daten

Sommersemester 2012

Teil 1: XML-Einführung

1.1. "Semistrukturierte" Daten

1.2. Entwicklung von XML

1.3. Aufbau von XML-Dokumenten

1.1. "Semistrukturierte Daten"

- "Wesen" von semistrukturierten Daten
- Dokumente vs. Daten

"Wesen" von Semistrukturierten Daten

- (relationales) Datenmodell ist eventuell zu starr: flexiblere Struktur (als Tabellen mit fix vorgegebenen Spalten mit fixem Datentyp)
- Schema ist nicht vorhanden (oder nicht sichtbar für den Benutzer):
  - Selbstbeschreibend (Strukturinformation als Teil der Daten und nicht in explizitem Schema)
  - Ein Schema kann optional vorhanden sein.

Flexible Struktur

- Die Suche nach Modellen für flexible und unregelmäßige Datenstruktur führte zu Modellen für semistrukturierte Daten
  - wenn relationale Datenbank viele Nullwerte hätte
  - wenn Daten unterschiedlichen Typ haben können.
- Gut geeignete Datenstruktur:
  - Baum
  - oder allgemeiner: Graph
- Wir können übliche DB Formate (Tabellen, OO-DB) in diesem Format darstellen.

Selbstbeschreibende Daten

- In Datenbanken wird zuerst ein Schema definiert, d.h.: Struktur + erlaubte Typen
- Bei Daten am Web ist häufig kein Schema vorhanden (bzw. für den Benutzer nicht sichtbar).
- Semistrukturierte Daten:
  - Selbstbeschreibende Daten: jeder Eintrag wird explizit mit seiner Beschreibung annotiert.
  - Schema (z.B. DTD oder XML Schema) ist optional
  - Vorteile: Interoperabilität, Erweiterbarkeit
  - Nachteil: Speicherplatzverschwendung bei Standardspeicherungsart (Wiederholung der Bezeichnungen)

Dokumente vs. Daten

- Dokumente:
  - Reiner Text ist problematisch für automatische Verarbeitung von Inhalten
  - Sichtbarmachen der Struktur (mittels Markup) erforderlich
- Daten:
  - starre Struktur, fixes Schema
  - Selbstbeschreibende Daten (mittels Markup) geben mehr Flexibilität
- XML: vereinigt die beiden Sichtweisen
  - Ursprünglich eher Dokumenten-Sicht
  - Mittlerweile Daten-Sicht mindestens gleich wichtig

Anwendungen von XML

- Dokument-Anwendungen
  - “menschlicher” Informationsaustausch
  - aber auch für Maschinen interpretierbare Daten
  - Klare Trennung von Struktur und Präsentation
    => transportables und leicht wiederverwendbares Dokument
  - "maßgeschneiderte" Präsentation mittels Stylesheets
- Daten-Anwendungen
  - Einheitliches, einfaches, robustes Daten-Austauschformat
  - automatisierter Datenaustausch mit Datenbanken, Programmen,...
  - native XML Datenbanken

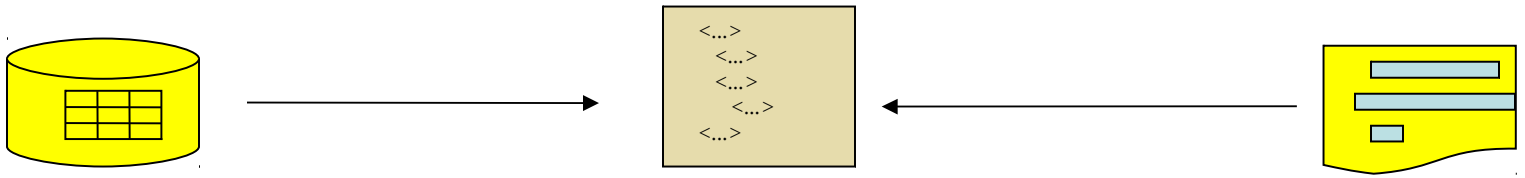

Unterschiedliche Forschungsinteressen

- Dokumentenwelt
  - Präsentationsformate (wie HTML)
  - Informationsaustauschformate
  - Document/Information Retrieval
- Datenbankwelt
  - Speichertechniken
  - Anfragesprachen
  - Datenmodelle, Methoden zur Strukturierung von Daten
  - Integrität/Konsistenz von Daten

Diese Grenzen verschwimmen.

1.2. Entwicklung von XML

- XML, SGML und HTML
- Applikationen und Standards
- Geschichte
- Tools

XML: eXtensible Markup Language

Wichtige Eigenschaften:

- Genormte, erweiterbare Auszeichnungssprache (W3C): kein ISO-Standard sondern eine W3C Recommendation
- Syntax zur Beschreibung (semi)strukturierter Information
- Trennung von Struktur und Präsentation
- Bereichsspezifische Dokumenttypen ("Applikationen")
- als Datenaustauschformat sehr gut geeignet

"XML will be the ASCII of the Web – basic, essential, unexciting" (Tim Bray)

SGML

- Standard Generalized Markup Language
- ISO Standard (1986)
- Für einzelne Applikationen kann eine bestimmte Dokumentenstruktur vorgegeben werden
  - Elemente und ihre Relationen werden beschrieben
- HTML ist eine Applikation von SGML
  - HTML enthält Formatierungsanweisungen, die von Browsern interpretiert werden
  - HTML-Syntax ist relativ flexibel bzw. Browser sind fehler-tolerant (z.B. inkorrekte Schachtelung von Elementen)

Bestandteile eines SGML-Dokuments

- SGML-Deklaration
  - Definiert „Umgebung“ eines SGML-Dokuments, d.h.: Regeln für DTD und Dokument-Instanz
  - z.B.: Zeichensatz, als Markup zu interpretierende Zeichen, zulässige Länge von Tags, zulässige Schachtelungstiefe, ...
- Dokumenttypdefinition (DTD)
  - Externes/internes DTD-Subset
- Dokument-Instanz
  - d.h.: der mit Markup annotierte Inhalt

Einschränkungen von XML (vs. SGML)

- Max. 2 Bestandteile eines XML-Dokuments:
  - Dokument-Instanz, optional DTD, keine SGML-Deklaration
  - aber implizit gibt es eine fixe SGML-Deklaration für XML
  - d.h.: XML ist eine echte Teilmenge von SGML
- Wohlgeformtheit ohne Gültigkeit möglich
- Keine Namen, die mit [Xx] [Mm] [Ll] beginnen
- Keine Auslassung/Abkürzung von Markup
- Attribute haben immer auch einen Attributwert
- Immer Unicode als Basiszeichensatz
- Keine Kapazitätsbeschränkungen

HTML vs. XML

- HTML
  - eine Applikation von SGML (eine fixe DTD)
  - über 100 *fixe* Tags
  - Browser sehr fehlertolerant (ignoriert DTD....)
  - In erster Linie für Präsentation (z.B. boldfaced, rot) bzw. Layout-Struktur (z.B. Tabellen, Listen)
  - Chaos: verschiedenste proprietäre Erweiterungen
- XML
  - eine Teilmenge von SGML
  - Metasprache für Markup Sprachen
  - keine vordefinierten Tags
  - strikte Syntax muss eingehalten werden
  - viele ergänzende Standards (XSD, Xpath, ...)
  - leicht zu lesen und zu verarbeiten

Warum XML?

- Einschränkungen von HTML
  - Fix vorgegebene Menge von Elementen
  - keine Trennung von Layout und Struktur
- Komplexität von SGML
  - unbrauchbare Optionen für Webapplikationen
  - schwierig für Entwicklung von Tools/Browsern
- Idee von XML
  - Vereinfachte Version von SGML (Teilmenge)
  - Optimiert für Informationsbereitstellung im Web
  - Soll HTML/SGML ergänzen (nicht ersetzen)

Was XML nicht ist ...

- XML ist keine Programmiersprache
- XML ist kein Netzwerk-Transportprotokoll
- XML ist keine Datenbank

Ein XML-Dokument *existiert* einfach. Es *tut* nichts.

Applikationen und Instanzen

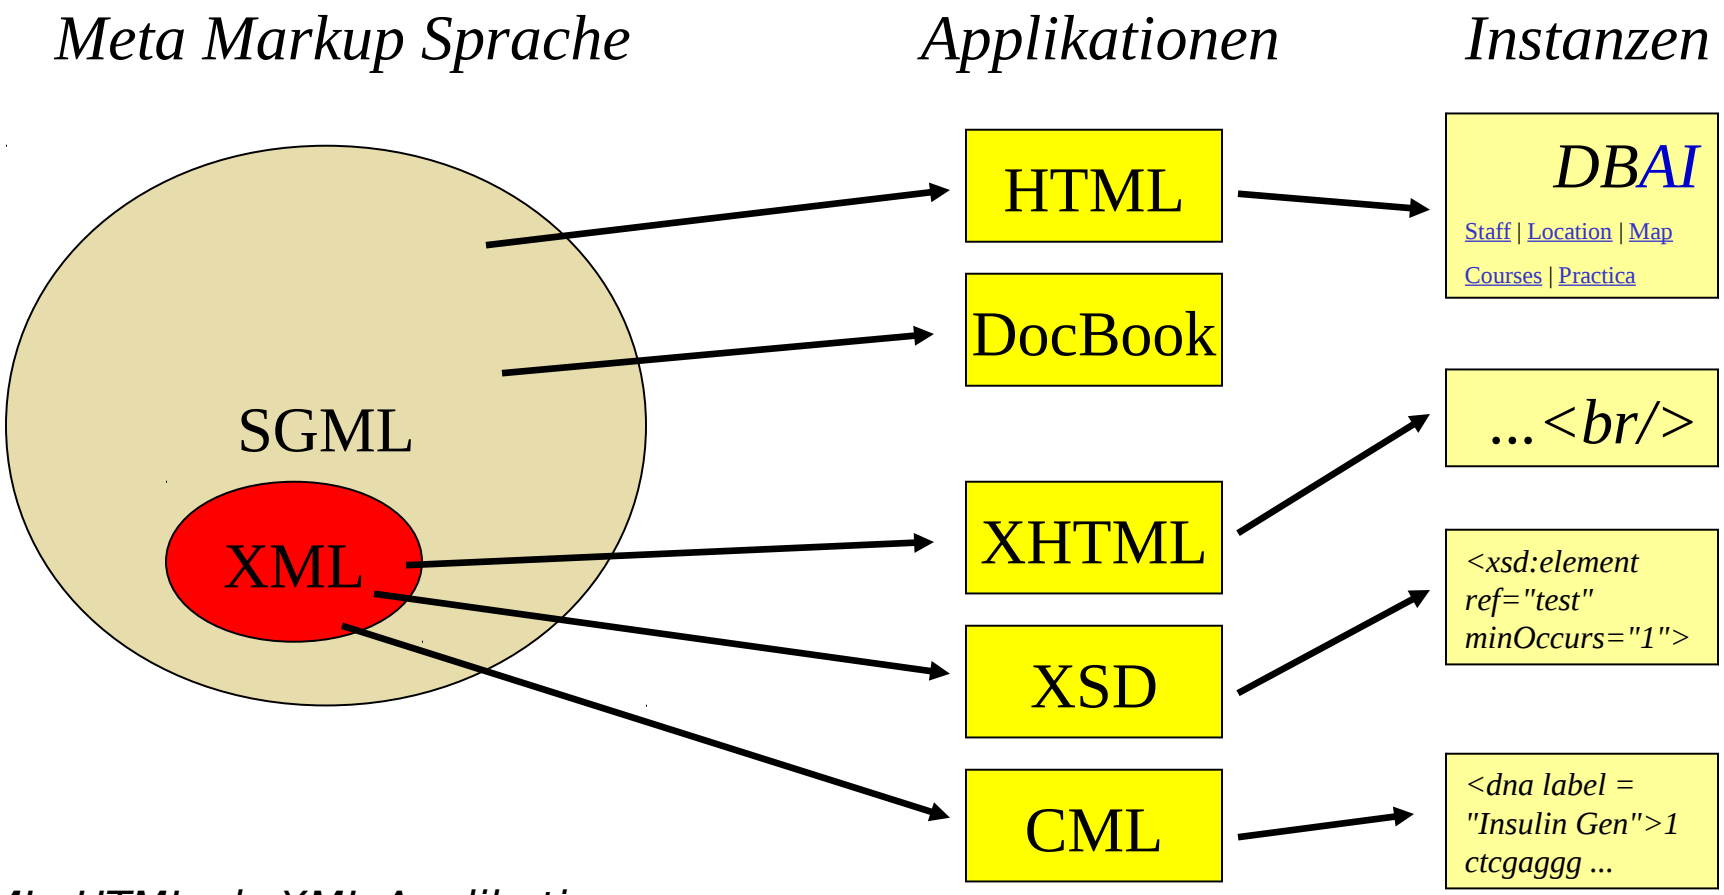

XHTML: HTML als XML Applikation
CML: Chemical Markup Language
XSD: XML Schema Definition

W3C: World Wide Web Consortium

Sechs Arten von Dokumenten

- Note:
  - kann jedes W3C Mitglied einreichen
  - noch keine Absichtserklärung des W3C
- Working Draft (WD)
  - aktueller Diskussionsstand
- Last Call WD
  - wenn festgelegte Ziele erreicht wurden
- Candidate Recommendation (CR)
  - Einreichungsbestätigung
- Proposed Recommendation
  - Implementierungen der Bestandteile sind vorhanden
- Recommendation
  - W3C "Standard" (ist kein offizieller Standard wie z.B. ein ISO Standard)

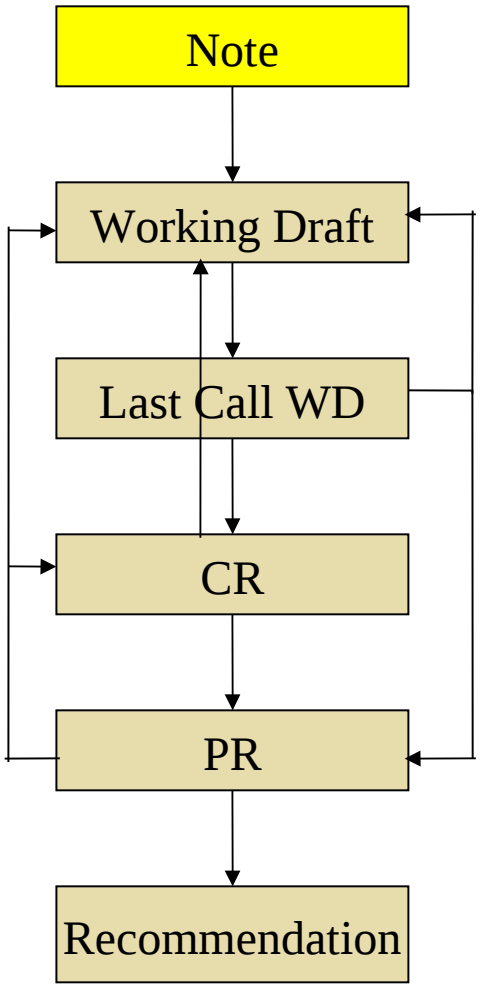

Rund um XML: Begleitende Standards

- Namespaces: Teil der XML-Recommendation
- W3C Schema-Sprachen: DTD, XSD
- Navigation: XPath
- Stylesheets: XSL
  - XSLT: Selektion, Transformation
  - XSL-FO: Präsentation
- XQuery: Abfragesprache (im Stil von SQL)
- (quasi-)standardisierte APIs
  - DOM
  - SAX
- viele weitere Standards

Geschichte

- Hypertext (1945)
  - beliebige Navigationspfade durch Dokumente
- GML (SGML Vorläufer) (1969)
- SGML ISO Standard (1986)
- HTML Tim Berners-Lee, CERN (1989)
- W3C gegründet (1994)
- SGML Subset Arbeitsgruppe (1996)
- XML 1.0 (1998)
- XSLT (1999)
- XML Schema (2001)
- laufend neue Recommendations

Einige XML Tools

- Browser
  - IE 6, Mozilla, Amaya (W3C Browser/Editor)
- XML Editoren: Altova's XMLSpy (www.xmlspy.com)
  - textbasiert vs. baumbasiert
- XML Parser:
  - Xerces (http://xerces.apache.org)
  - libxml-Bibliothek (http://xmlsoft.org)
    - xmllint – commandline tool
    - Windowsversion http://www.zlatkovic.com/pub/libxml
- XSLT:
  - Xalan (http://xalan.apache.org),
  - Saxon (www.saxonica.com).

1.3. Aufbau von XML-Dokumenten

- Baumstruktur
- Elemente
- Attribute
- Header
- Kommentare
- CDATA
- Processing Instructions
- Entitäten
- Unicode

Beispiel: XML Dokument

```
<?xml version="1.0" encoding="ISO-8859-1"?>
<!-- DBAI -->
<lehre>
  <veranstaltung jahr="2012">
    <titel>Semistrukturierte Daten</titel>
    <vorbesprechung>
      <datum>Do 1.3.</datum>
      <zeit cum_tempore="yes">9:00</zeit>
      <ort>HS 8 Heinz Parkus</ort>
    </vorbesprechung>
    <schlagwort>XML</schlagwort>
    <schlagwort>DTD</schlagwort>
    <schlagwort>SGML</schlagwort>
  </veranstaltung>
</lehre>
```

Beispiel: Bestandteile eines XML-Dokuments

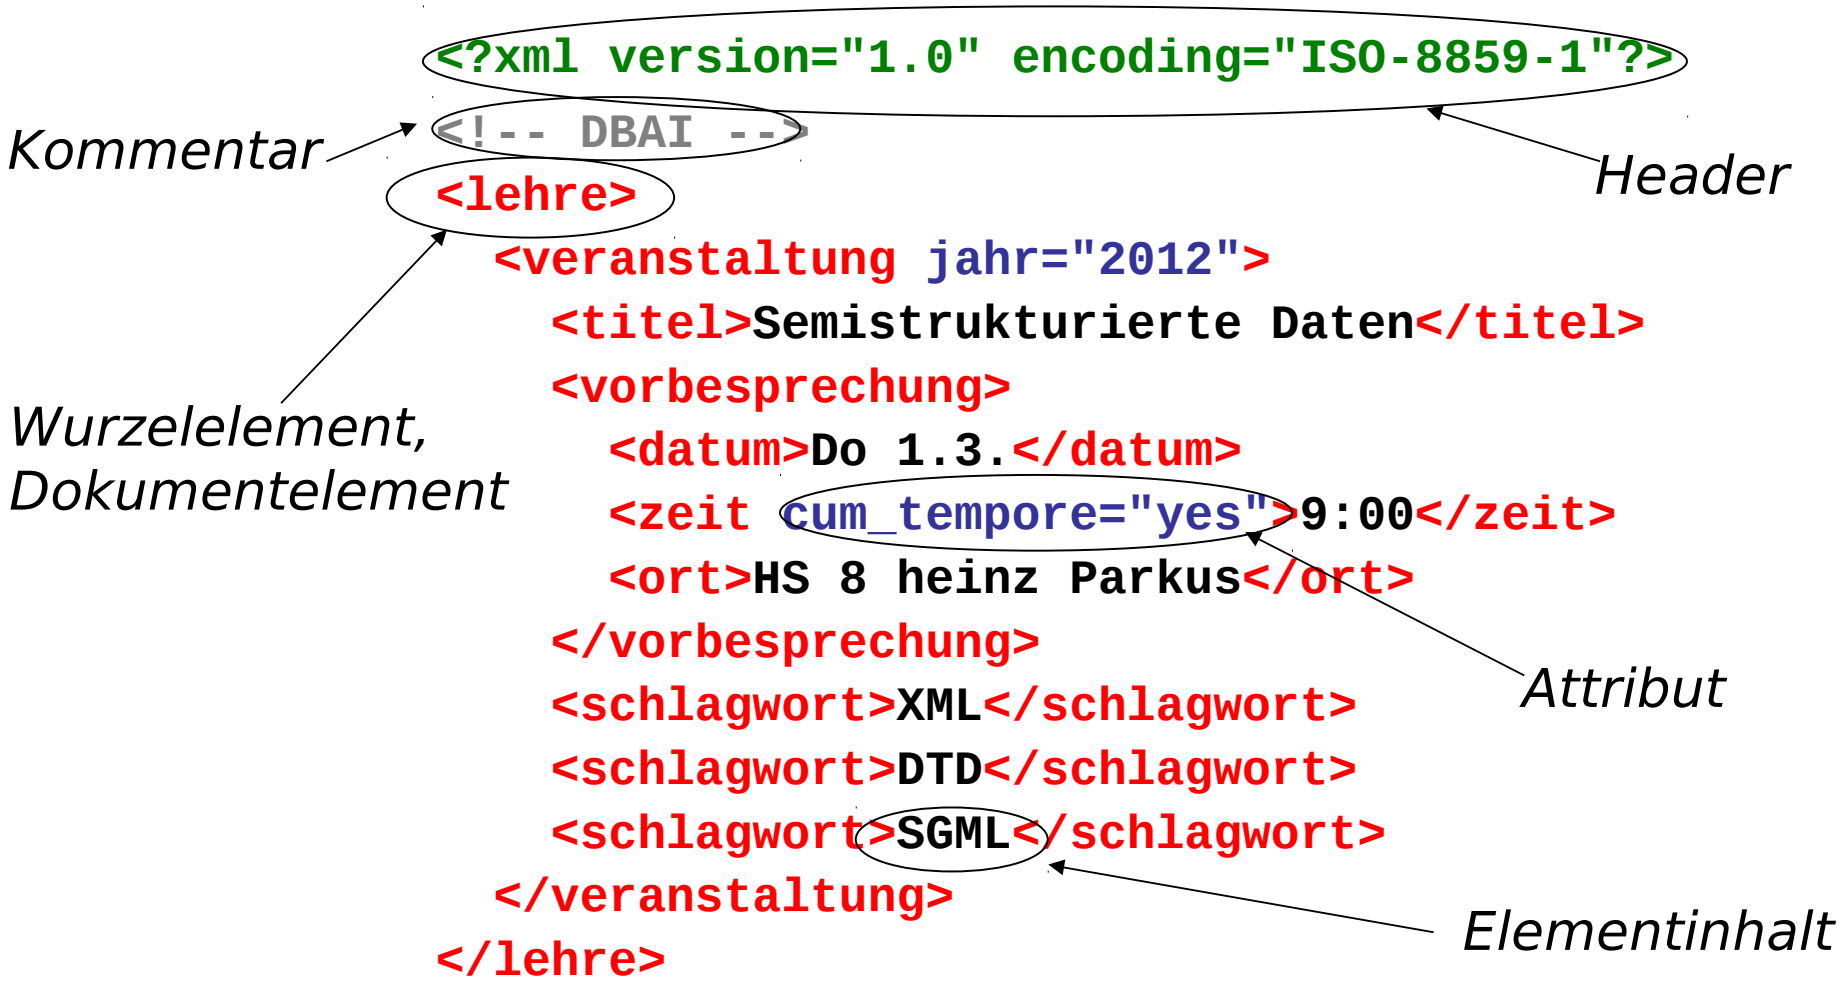

Beispiel: Dokumentenbaum

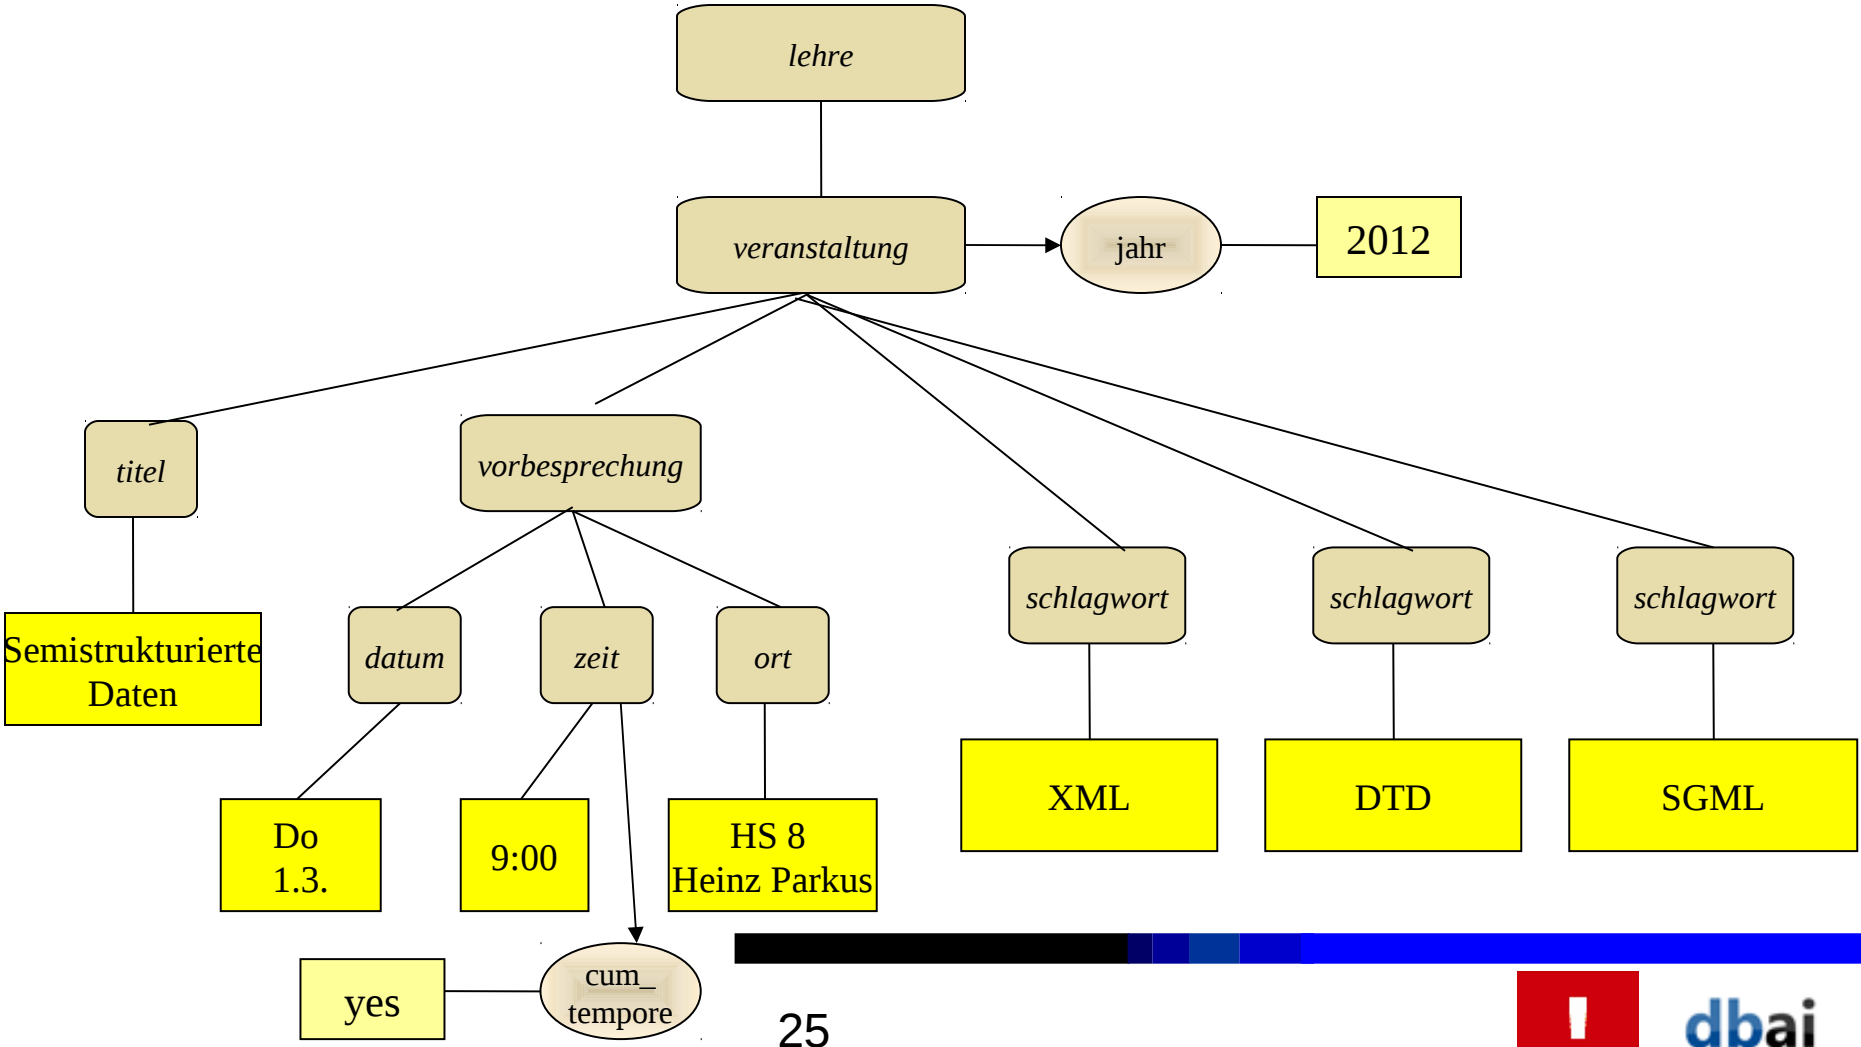

Struktur eines XML-Dokuments

- Baumstruktur
  - keine Einschränkungen der Baumstruktur durch den XML-Standard (aber natürlich mittels Schema möglich)
  - ist selbstbeschreibend
  - Die Ordnung der Elemente ist signifikant
- Unterscheidung Zeichendaten vs. Markup
  - Zeichendaten beherbergen die Information
  - Markup beherbergt die Struktur
  - beide sind einfach als Text abgelegt
  - Markup steht innerhalb spitzer Klammern: <.....>
  - Beispiel: `<lehre>`

Elemente

- beherbergen die strukturelle Information
- annotieren Text mit Markup Namen
- Elementname innerhalb spitzer Klammern

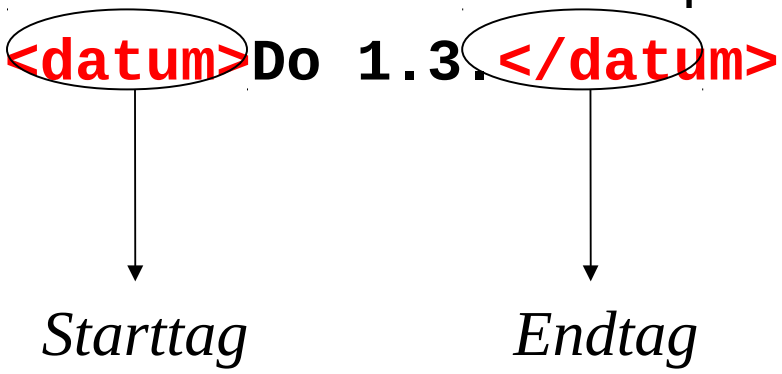

- Gemischter Inhalt ist erlaubt, d.h.:
  ein Element kann Text oder Elemente oder beides enthalten

```
<datum><tag>Do</tag>1.3.</datum>
```

Elementverschachtelung

- Element-Inhalt nicht auf Text beschränkt
- kann andere Elemente enthalten
- beliebige Baumtiefe und Wiederholungen

```
<ebayitem>
  <item>...</item>
  <price>...</price>
  <description>...</description>
  <description>...</description>
</ebayitem>
<yahooitem>
  <item>...</item>
  <price>...</price>
  <description>...</description>
</yahooitem>
<item>
  <item>...</item>
  <price>...</price>
  <description>...</description>
</item>
```

Regeln für Elementnamen

- XML selbst definiert keine Elementnamen
- Start mit Buchstaben oder Unterstrich
- Enthält Buchstaben, Ziffern, Unterstrich, Punkt, Bindestrich
- Buchstaben können aus beliebiger Sprache stammen (Unicode)
- Doppelpunkt erlaubt, hat aber spezielle Bedeutung
- Keine Zwischenräume erlaubt!
- Nicht beginnen mit XML (beliebig groß/klein)
- Case Sensitivity (ungleich HTML)
- Abkürzung für leere Elemente

  `<geblockt/>` anstatt `<geblockt></geblockt>`

Einige Beschränkungen

- Genau ein Wurzelelement pro XML Dokument
  - Name nicht vorgegeben
  - Bei Vereinigungen von Dokumenten: neuen Wurzelknoten hinzufügen
  - auf Ebene von Wurzelelement sonst nur Kommentare und Processing Instructions erlaubt
- Start- und Endtags
  - jedes Starttag muss geschlossen werden
    Beispiel: **
** alleine nicht erlaubt (lautet in XHTML **
**)
  - keine verschränkten Tags, z.B.:
  - erlaubt: **boldbold-italicbold**
    nicht erlaubt: **boldbold-italicitalic**

Attribute

- Beschreiben üblicherweise Elementcharakteristika
- Schreibweise:
  - **<attributname> = <attributwert>**
  - Attributwert ist eine Zeichenkette in " " oder ' '.
- Ein Element kann 0 bis beliebig viele Attribute haben.
- Jeder Attributname darf nur ein Mal pro Element vorkommen
  Beispiel: **<preis waehrung="$" waehrung="€">** nicht erlaubt

Attribute

- Die Reihenfolge der Attribute ist nicht signifikant
  - im Gegensatz zu Elementen
- Attribute können keine Kinder haben
  - nur Textwerte
- Datentyp von Attributen kann mittels Schema-Definition (z.B. DTD, XML Schema) beschränkt werden.
- Nicht alle Zeichen sind in Attributwerten erlaubt:
  - z.B.: "<"
  - Entitäten verwenden
  - oder (binäre) Daten codieren

Attribute

- Namensbeschränkungen wie bei Elementen
- Attribute stehen innerhalb des Starttags
- Attributwert immer in Anführungszeichen
  - können einfach ' ' oder doppelt " " sein
  - ' und " dürfen in einem Attribut nicht gemischt werden
  - jeweils andere Anführungszeichen innerhalb verwendbar
  - Attributwerte können leer sein: ""
- Beispiel: `<zeit cum_tempore="yes">`
- vordefinierte Attribute:
  - **`xml:space`** Whitespace erhalten oder löschen (preserve,default)
  - **`xml:lang`** zur Sprachspezifikation von Inhalt, z.B. "en-GB"
  - bei jedem Element möglich
  - Attributwert wird an Kindelemente vererbt

Richtlinien

- Element vs. Attribut
  - als Attribut eher systeminterne Dinge; sagt etwas darüber, wie der Elementinhalt zu interpretieren ist.
  - als Element eher Dinge für den Benutzer und wo Unterstruktur nötig ist oder Daten über viele Zeilen
- Einrückungen
  - bequemere Lesbarkeit
  - Whitespaces werden standardmäßig gefiltert
- XML ungleich Semantik
  - Bezeichnungen bedeuten nur für Menschen etwas
  - Semantik nur durch Applikation, d.h.: die Tags haben für die jeweilige Applikation eine klar definierte Semantik, z.B. Tag <element> in XSD, in XSLT, in CML

Whitespaces

- Whitespaces (Leerzeichen, Tabulator, Zeilenumbruch) treten in zwei Rollen auf:
  - Formatierung des Files, Einrückungen
    - werden von Parsern ignoriert oder verschmolzen
  - als Elementinhalt
    - führende und endende Whitespaces ignorieren?
    - aufeinanderfolgende Whitespaces verschmelzen?
      (je nach Parser; vordefiniertes Attribut **`xml:space`**)
- Folge: Repräsentation von

  `<lehre><titel>SSD</titel> <nummer id="1811”/></lehre>`

  hängt von diversen Faktoren ab:
  - hat Element **`lehre`** gemischten Inhalt?
  - ist der Parser validierend?
- Wichtig: Damit ein Element **`<nummer id="1811”></nummer>`** leer ist, muss der Endtag ummittelbar nach dem Starttag kommen.

Header und Kommentare

- XML Deklaration
  - erste Zeile `<?xml version="1.0"?>`
  - ist optional
  - weitere Information wie z.B. encoding

```
<?xml version="1.0" encoding="ISO-8859-1"?>
```

- Kommentare
  - <!-- -->
  - für Menschen
  - wird vom Parser nicht interpretiert (und möglicherweise ignoriert)
  - entweder vor oder nach Markup
  - Metacharacters (wie "<", "&") sind in Kommentaren erlaubt

CDATA und "verbotene" Zeichen

- CDATA
  - Character Data
  - nicht vom Parser bearbeitet
  - Entitäten und Tags innerhalb nicht erkannt
  - beginnt mit **<![CDATA[**
  - endet mit **]]>** (dieses Markup ignoriert Parser nicht)
- Darstellung von beliebigen binären Zeichen
  - als externe Entität (siehe 2. VL-Termin)
  - codiert (z.B.: base64 oder hexBinary) im XML-Dokument

Processing Instructions

- Einfügen von "Nicht-XML-Statements"
  - Um Anweisungen an eine Applikation zu geben (Für diesen Zweck auf keinen Fall Kommentare "missbrauchen"!)
- Typische Anwendung:
  - Stylesheetverknüpfung:
  - Anweisung bzgl. Layout an den Browser.
  - **`<?xml-stylesheet type="text/xsl" href="lva.xsl"?>`**
- Weiteres Beispiel:
  - **`<?editor href="editor" load doc?>`**
  - Alles hinter "editor" ist ein großer Datenblock; manche Parser versuchen, wenn es geht, diesen Teil wie Attribute zu behandeln.

Entitäten

- Deklaration von Entitäten
  - in DTD (siehe 2. VL-Termin)
  - vordefinierte Entitäten
- Entitätsreferenzen
  - innerhalb von & ... ;
  - Beispiel: <tag>&mi;</tag> für Mittwoch
- vordefinierte Entitäten
  - nur für folgende 5 Zeichen: **< > & ' "**
  - Entitäten: **< > & ' "**
  - Character-Referenzen: **Ó** (dezimal), **ó** (hex)

Zeichensätze + Zeichenkodierungen

- Basiszeichensatz für XML: Unicode
- ca. 100.000 Zeichen:
  - Buchstaben aller Sprachen
  - mathematische Zeichen
  - etc.
- Unicode Consortium + ISO Standard
  - http://www.unicode.org/
- Unicode gibt jedem Zeichen eine eindeutige Zahl
  - Unicode ist kein Font,
  - Fähigkeit Unicode zu bearbeiten ist unabhängig von Fähigkeit zur Anzeige

Zeichensätze + Zeichenkodierungen

- XML-Parser müssen zumindest folgende Kodierungen unterstützen:
  - UTF-8 (Unicode Transformation Format – 8)

  Standard 7-bit ASCII als 8 Bits,

  andere Zeichen mehrere Bytes lang
  - UTF-16

  16 Bits Kodierung für alle "gebräuchlichen" Unicode-Zeichen,

  andere Zeichen 4 Bytes lang
- Jede andere Kodierung als UTF braucht eine spezielle Deklaration im XML-Dokument
- Andere Zeichensätze + Kodierungen (Unicode-Teilmengen), z.B.: Latin-1 (ISO 8859-1):
  - Benötigt 8 bits
  - Umfasst 7bit-ASCII + Sonderzeichen für Deutsch, Französisch, …